Difusiones y Score

La matemática detrás de los modelos generativos modernos

Gonzalo Josué Spina

Universidad de Buenos Aires • Facultad de Ciencias Exactas y Naturales • Cálculo Estocástico, 2026

1. El problema



Muestras de $p_0(x)$ (desconocida)

Queremos generar nuevas muestras de $p_0(x)$.

Problema: $p_0(x)$ es desconocida; solo tenemos datos.

Idea: corromper los datos con ruido hasta llegar a una distribución **conocida** π; luego invertir el proceso.

2. Difusiones como modelos generativos

Definimos un proceso estocástico **forward** que transforma p_0 gradualmente en una distribución conocida π:

$$\mathrm{d}X_t = f(X_t, t)\ \mathrm{d}t + g(t)\ \mathrm{d}B_t, \qquad X_0 \sim p_0.$$

Diseñando f y g para que $p_T \approx \pi$ (e.g. gaussiana), obtenemos un proceso que *destruye* la estructura de los datos.

Resultado clave (Anderson, 1982). El proceso corriendo en tiempo inverso $\tau = T - t$ es también una difusión, con la **misma estructura** que el forward más un término adicional: el **score**.

3. Proceso forward: Ornstein-Uhlenbeck

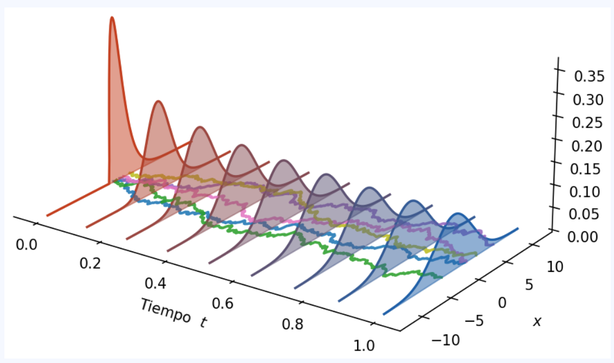
Difundimos los datos con el **proceso OU** ($f(x,t) = -x$, $g = \sigma$):

$$\mathrm{d}X_t = -X_t\ \mathrm{d}t + \sigma\ \mathrm{d}B_t, \qquad X_0 \sim p_0.$$

La solución desde $X_0 = x_0$ es:

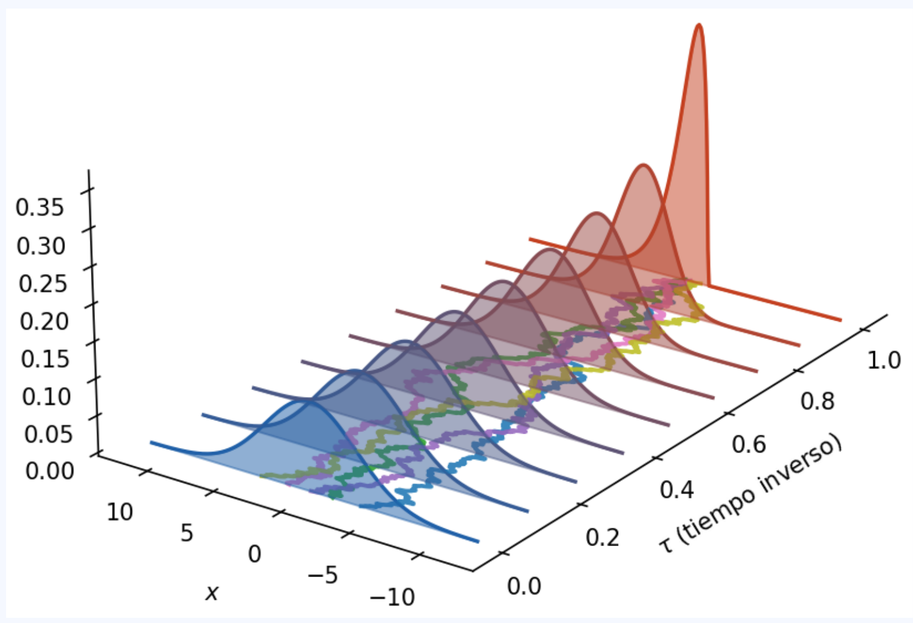
$$X_t \mid x_0 \ \sim\ \mathcal{N}\Big(x_0\, e^{-t},\ \tfrac{\sigma^2}{2}(1 - e^{-2t})\Big).$$

El autovalor $\lambda = -1 < 0$ del drift garantiza convergencia (al igual que en $\dot{x} = -x$), y para T grande $p_T \approx \mathcal{N}(0,\, \sigma^2/2)$.



4. Anderson (1982): caso OU

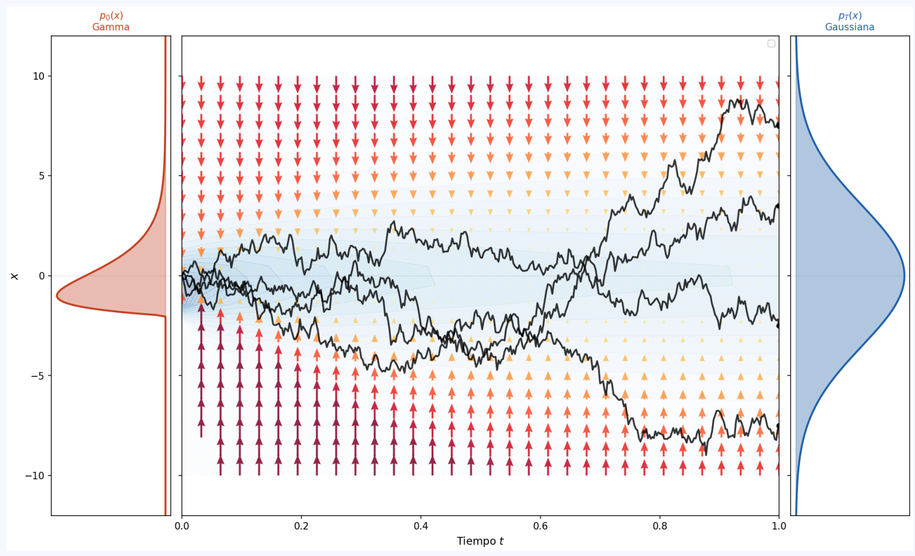
$$\mathrm{d}\hat{X}_\tau = \Big[\hat{X}_\tau + \sigma^2\, \nabla_x \log p_{T-\tau}\Big]\, \mathrm{d}\tau + \sigma\ \mathrm{d}\bar{B}_\tau.$$



5. El score: qué es y qué hace

El ingrediente desconocido $\nabla_x \log p_t(x)$ se llama **score**. Es el gradiente del logaritmo de la densidad: apunta hacia las regiones de mayor probabilidad y es el motor que impulsa el proceso inverso.

El campo vectorial muestra cómo varía con t y x (de Gamma a Gaussiana). Las trayectorias negras son partículas guiadas por el score.



Objetivo: aprender $s_\theta(x,t) \approx \nabla_x \log p_t(x)$.

6. Cómo aprender el score

Hyvärinen (2005). El objetivo natural es intratable porque requiere $\nabla_x \log p$:

$$J_{\mathrm{nat}}(\theta) = \tfrac{1}{2}\,\mathbb{E}\big[\|s_\theta(x) - \nabla_x \log p(x)\|^2\big].$$

Integrando por partes se elimina ese término:

$$J(\theta) = \mathbb{E}\big[\mathrm{tr}\big(\nabla_x s_\theta(x)\big) + \tfrac{1}{2}\,\|s_\theta(x)\|^2\big] + \mathrm{cte}.$$

Vincent (2011). Consideremos la marginal ruidosa $p_\sigma(\tilde{x}) = \int q_\sigma(\tilde{x} \mid x)\, p_0(x)\ \mathrm{d}x$ con $q_\sigma(\tilde{x} \mid x) = \mathcal{N}(x, \sigma^2 I)$. Diferenciando bajo la integral se obtiene la identidad de score:

$$\nabla_{\tilde{x}} \log p_\sigma(\tilde{x}) = \mathbb{E}_x\Big[\nabla_{\tilde{x}} \log q_\sigma(\tilde{x} \,|\, x) \ \Big|\ \tilde{x}\Big].$$

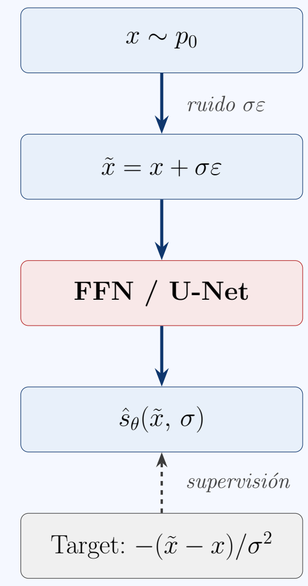
El score de la **marginal** (desconocido) es la esperanza del score de la **condicional** (conocido):

$$\nabla_{\tilde{x}} \log q_\sigma(\tilde{x} \mid x) = -\frac{\tilde{x} - x}{\sigma^2}.$$

Minimizar sobre la condicional es equivalente a minimizar sobre la marginal, lo que da el objetivo práctico:

$$\tilde{J}(\theta) = \mathbb{E}\left[\left\| s_\theta(\tilde{x}, \sigma) + \frac{\tilde{x} - x}{\sigma^2} \right\|^2\right].$$

7. ¿Qué aprende la red?



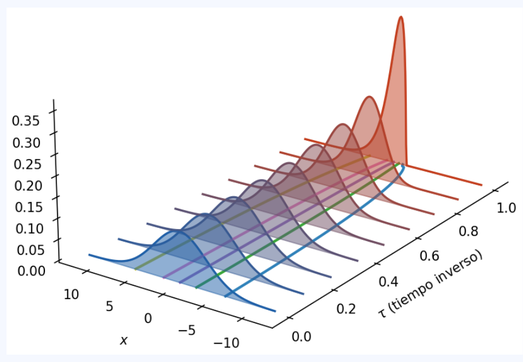
La red nunca aprende una densidad.

Aprende un **campo vectorial** $x \mapsto \hat{s}_\theta(x, t)$.

8. Probability flow ODE

El proceso inverso **no necesita ser ruidoso**. Existe una ODE determinista con las mismas marginales p_t:

$$\mathrm{d}\hat{X}_\tau = \Big[\hat{X}_\tau + \tfrac{\sigma^2}{2}\, \nabla_x \log p_{T-\tau}\Big]\, \mathrm{d}\tau.$$



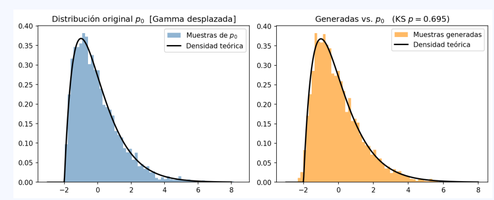
Dado x_T, el camino hacia x_0 es **determinista y único**.

9. Cierre: el pipeline funciona

Pipeline de generación:

1. Muestrear $\hat{X}_T \sim \mathcal{N}(0,\, \sigma^2/2)$
2. Correr la EDE inversa (o la ODE) de T a 0
3. Obtener $\hat{X}_0 \sim p_0$

Con el score aprendido vía denoising score matching, la EDE inversa recupera muestras de p_0 partiendo de $\mathcal{N}(0,\, \sigma^2/2)$:



Test KS: $p = 0.695$ — no se rechaza H_0: $\hat{p} = p_0$.

Geometría + probabilidad + aprendizaje profundo.

LaTeX TikZposter